

# 第六章 非参数概率密度函数的估计

参数估计：假设数据服从某种分布

非参数估计：直接利用样本估计分布



# 参数估计的局限:

- 参数估计方法: 要求**已知**分布的具体形式
- 实际情况可能是: 不知道分布的形式或者不是典型的分布形式




基本原理

Parzen窗法

$k_N$  近邻法

# 基本原理

设  $p(x)$  是  $x$  的总体概率密度函数



随机变量  $x$  落入区域  $R$  的概率:

$$P = \int_R p(x) dx$$

$k$  的期望:

$$E[k] = NP$$


$$E[k] = NP$$

得出

$$k \approx N\hat{P}$$

则

$$\hat{P} \approx \frac{k}{N}$$




意义:  $k/N$  是  $P$  的一个好的估计

我们的目标是估计概率密度函数  $p(\mathbf{x})$  本身

假设  $p(\mathbf{x})$  是连续函数，并且取区域  $R$  足够小，这样就可以认为  $p(\mathbf{x})$  在区域  $R$  上保持不变，则

概率

$$P = \int_R p(x) dx = p(x) V$$



其中， $V$  是区域  $R$  的体积， $\mathbf{x}$  是  $R$  中的某一个点


$$\hat{P} \approx \frac{k}{N}$$

$$\hat{P} = \int_R p(x) dx = \hat{p}(x) V$$

点  $\mathbf{x}$  的概率密度  $p(\mathbf{x})$  的估计值  
它依赖于：

- ✓ 样本数目  $N$
- ✓ 包含  $\mathbf{x}$  的区域  $R$  的体积  $V$
- ✓ 落入 区域  $R$  的样本数  $k$

$$\hat{p}(x) = \frac{k/N}{V}$$






## 分析公式的性质

$$\hat{p}(x) = \frac{k/N}{V}$$


**情形1**：体积  $V$  固定。**理论上**， $N$  越来越多，  
则比值  $k/(NV)$  按概率意义收敛于概率。**实际上**，  
只能得到  $p(\mathbf{x})$  的空间平均估计：



$$p(\mathbf{x}) \approx \frac{k}{NV} = \frac{\hat{P}}{V} = \frac{\int_R p(\mathbf{x}) d\mathbf{x}}{\int_R d\mathbf{x}}$$

情形2：样本数固定。体积  $V$  趋近于零，随着区域  $R$  的不断缩小，一种可能性是出现不包含任何样本，从而使  $p(\mathbf{x})=0$ ；另一种可能性是包含几个样本，但是  $p(\mathbf{x})=\infty$

非常不光滑



情形3: (实际情况), 样本数是有限的, 体积不可能足够小。此时,  $k/N$  和  $p(\mathbf{x})$  存在随机性, 即它们有一定的方差

假设可以使用无限多样本，从理论上分析公式的性质

估计的方法：为了估计点  $\mathbf{x}$  的概率密度，构造  
一系列包含  $\mathbf{x}$  的区域序列  $R_1, R_2, \dots, R_N, \dots$

其中，对于  $R_1$  用一个样本来估计， $R_2$  用两个样本来估计，依次类推

记:

$V_N$ :  $R_N$ 的体积

$k_N$ : 落入区域  $R_N$  的样本数

$\hat{p}_N(\mathbf{x})$ :  $p(\mathbf{x})$ 的第  $N$  次估计

则

$$\hat{p}_N(\mathbf{x}) = \frac{k_N/N}{V_N}$$

$$\rightarrow p(x)$$

如果它要收敛于  $p(\mathbf{x})$  , 则需要满足三个条件

需满足的三个条件:

$$(1) \quad \lim_{N \rightarrow \infty} V_N = 0$$

含义:

如果区域平滑地缩小,  $p(\mathbf{x})$  在点  $\mathbf{x}$  连续, 这一条件使空间平均  $P/V$  收敛于概率  $p(\mathbf{x})$

(2)  $\lim_{N \rightarrow \infty} k_N = \infty$

含义:

对于  $p(\mathbf{x}) \neq 0$  的点有意义, 可以使频度  $k_N/N$  在  
概率意义上收敛于概率  $P$

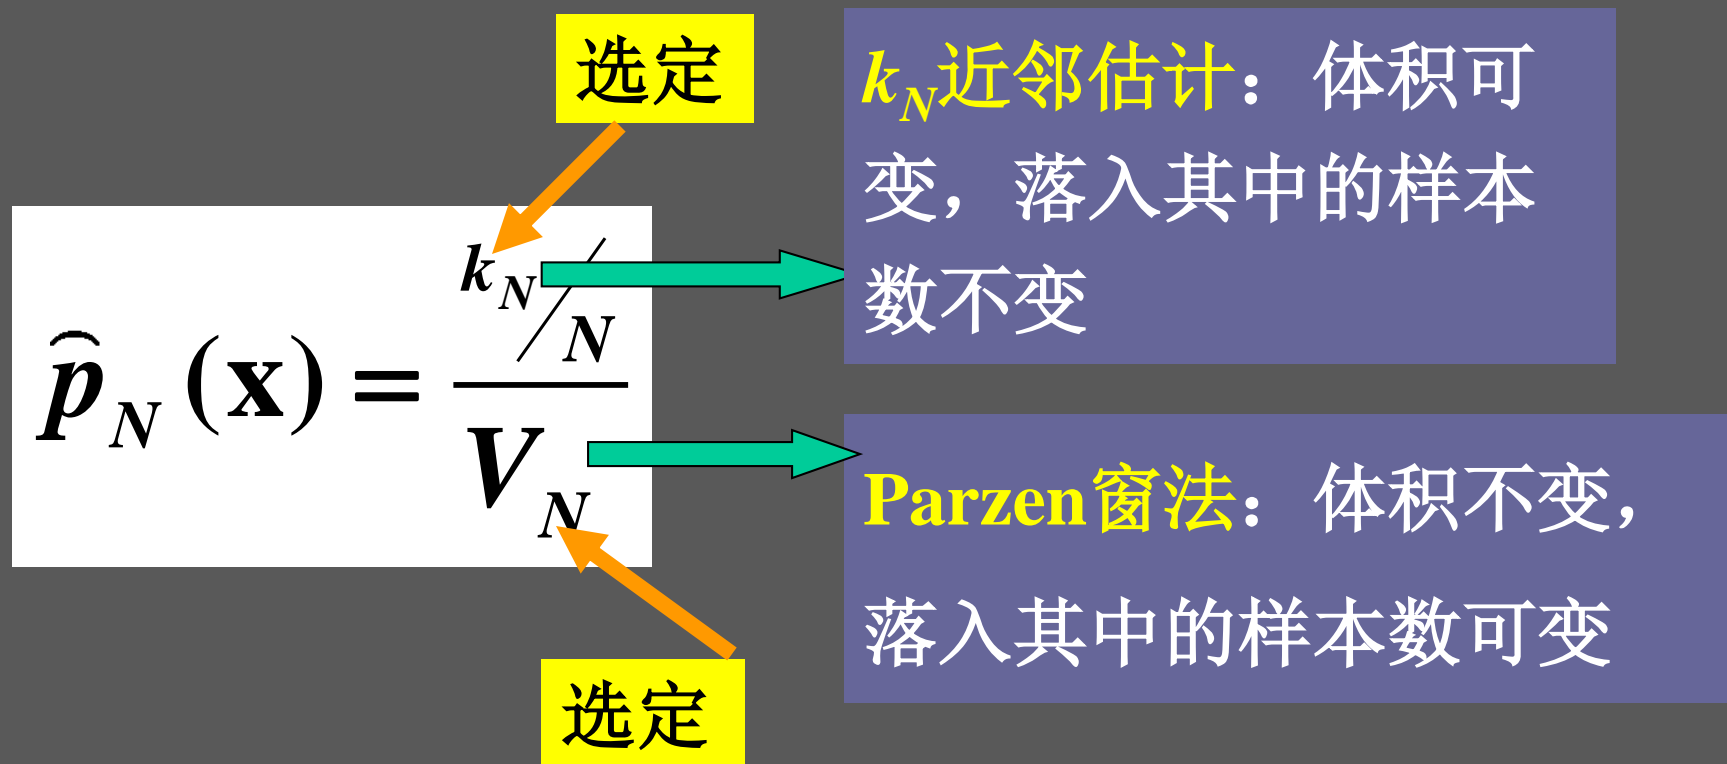
(3)

$$\lim_{N \rightarrow \infty} \frac{k_N}{N} = 0$$

尽管在一个小区域  $R_N$  内落入了大量样本，但是与总样本数相比仍然**非常少**



现在，有**两种**方法，可以选取满足上述**三个**条件的区域序列，从而导出**两种**非参数估计方法：



Parzen窗法: 使区域序列 $V_N$ 为 $N$ 的某个函数, 对于 $N$ 较大的数据集,  $V_N$  的取值应该较小

$k_N$ 近邻估计: 使 $k_N$ 为 $N$ 的某个函数,  $V_N$  定义为刚好包含  $\mathbf{x}$  的  $k_N$  个近邻样本的 区域  $R_N$  的体积

# Parzen窗法

1 Parzen窗估计的基本概念

2 估计量  $\hat{p}_N(\mathbf{x})$  为概率密度的条件

3 窗函数的选择

4 窗宽对估计量的影响

5 估计量的性质

# 1 Parzen窗估计的概念

估计概率密度的基本公式

$$\hat{p}_N(\mathbf{x}) = \frac{k_N / N}{V_N}$$


设区域  $R_N$  是以  $h_N$  为棱长的  $d$  维超立方体，则

立方体的体积为

$$V_N = h_N^d$$

定义一个窗函数:


$$\varphi(\mathbf{u}) = \begin{cases} 1, & |u_j| \leq \frac{1}{2}, j=1, \dots, d \\ 0, & \text{其他} \end{cases}$$



上述函数也称为方窗函数

求出落入超立方体内的样本个数？

立方体：以  $\mathbf{x}$  为中心、体积为  $V_N$  的立方体



如果某一个样本  $\mathbf{x}_i$  落入该立方体，则

$$\varphi\left(\frac{\mathbf{x}-\mathbf{x}_i}{h_N}\right) = 1$$

否则

$$\varphi\left(\frac{\mathbf{x}-\mathbf{x}_i}{h_N}\right) = 0$$

落入该立方体的样本数为

$$k_N = \sum_{i=1}^N \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_N}\right)$$

点  $\mathbf{x}$  的概率密度

$$\hat{p}_N(\mathbf{x}) = \frac{k_N/N}{V_N} = \frac{1}{N} \sum_{i=1}^N \frac{1}{V_N} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_N}\right)$$



Parzen窗法估计的基本公式

说明:

1 可以取其他形式的窗函数

2 窗函数的可选定义：每一个样本对窗函数的贡献依赖于它到  $\mathbf{x}$  的距离（ $\mathbf{x}$  为立方体的中心）

3 这种估计可以看成  $\mathbf{x}$  与  $\mathbf{x}_i$  的函数的平均



## 2 估计量是密度函数的条件

概率密度函数应该满足的条件：

$$(1) \quad p(\mathbf{x}) \geq 0, \mathbf{x} \in \mathfrak{R}^d$$

$$(2) \quad \int_{\mathfrak{R}^d} p(\mathbf{x}) d\mathbf{x} = 1$$

$$\hat{p}_N(\mathbf{x}) = \frac{1}{N} \sum_{i=1}^N \frac{1}{V_N} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_N}\right)$$

这一估计量是  
概率密度吗？

只要窗函数满足下列条件

$$(1) \quad \varphi(\mathbf{u}) \geq 0$$

$$(2) \quad \int \varphi(\mathbf{u}) d\mathbf{u} = 1$$

(意义): 窗函数本身具有概率密度函数的形式)

$$\hat{p}_N(\mathbf{x}) = \frac{1}{N} \sum_{i=1}^N \frac{1}{V_N} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_N}\right)$$

就是**概率密度函数**

**证明**: 满足条件(1)

因为

$$\varphi(\mathbf{u}) \geq \mathbf{0}$$

则

$$\hat{p}_N(\mathbf{x}) = \frac{1}{N} \sum_{i=1}^N \frac{1}{V_N} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_N}\right) \geq \mathbf{0}$$

满足条件(2)

$$\int \hat{p}_N(\mathbf{x}) d\mathbf{x} = \int \frac{1}{N} \sum_{i=1}^N \frac{1}{V_N} \varphi\left(\frac{\mathbf{x}-\mathbf{x}_i}{h_N}\right) d\mathbf{x}$$

$$= \frac{1}{N} \sum_{i=1}^N \int \frac{1}{V_N} \varphi\left(\frac{\mathbf{x}-\mathbf{x}_i}{h_N}\right) d\mathbf{x}$$

$$= \frac{1}{N} \sum_{i=1}^N \int \varphi(\mathbf{u}) d\mathbf{u}$$

$$= \frac{1}{N} N$$

$$= 1$$

$$V_N = h_N^d$$

### 3 窗函数的选择

**基本原则**：窗函数必须满足两个基本条件

$$(1) \quad \varphi(u) \geq 0$$

$$(2) \quad \int \varphi(u) du = 1$$

**常用的窗函数**有：


(1) 方窗函数

(2) 正态窗函数

(3) 指数窗函数

## 方窗函数 (前面已介绍)


$$\varphi(\mathbf{u}) = \begin{cases} 1, & |u_j| \leq \frac{1}{2}, j=1, \dots, d \\ 0, & \text{其他} \end{cases}$$



一维的图形

## 正态窗函数

$$\varphi(\mathbf{u}) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2} \mathbf{u}^T \mathbf{u}\right)$$




一维图形

## 指数窗函数

向量的长度或者模

$$\varphi(\mathbf{u}) = \exp\left(-\frac{1}{2} \|\mathbf{u}\|\right)$$



一维图形



$$\hat{p}_N(\mathbf{x}) = \frac{1}{N} \sum_{i=1}^N \frac{1}{V_N} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_N}\right)$$

$$V_N = h_N^d$$

说明:

对于一个实际问题，估计结果的**好坏**取决于窗

函数的类型及参数（**窗宽**）

## 4 窗宽对估计量的影响

### 问题:

只有有限个样本数的条件下，讨论窗宽对估计量的影响

定义一个新函数

$$\delta_N(\mathbf{x}) = \frac{1}{V_N} \varphi\left(\frac{\mathbf{x}}{h_N}\right)$$

则

$$\hat{p}_N(\mathbf{x}) = \frac{1}{N} \sum_{i=1}^N \frac{1}{V_N} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_N}\right)$$

$$= \frac{1}{N} \sum_{i=1}^N \delta_N(\mathbf{x} - \mathbf{x}_i)$$

取平均

$$\mathbf{V}_N = \mathbf{h}_N^d$$


$$\delta_N(\mathbf{x}) = \frac{1}{V_N} \varphi\left(\frac{\mathbf{x}}{h_N}\right)$$

窗宽  $h_N$  的大小会影响  $\delta_N(\mathbf{x})$  的幅度大小，两者之间成**反比**关系

$$\mathbf{V}_N = \mathbf{h}_N^d$$

$$\delta_N(\mathbf{x}) = \frac{1}{V_N} \varphi\left(\frac{\mathbf{x}}{h_N}\right)$$

$$\hat{p}_N(\mathbf{x}) = \frac{1}{N} \sum_{i=1}^N \delta_N(\mathbf{x} - \mathbf{x}_i)$$




**情形 1:** 窗宽  $h_N$  很大, 此时  $\delta_N(\mathbf{x} - \mathbf{x}_i)$  的幅度很小, 并且只有离  $\mathbf{x}$  很远的样本对概率密度才无贡献。因此, 密度估计值是  $N$  个宽度较大、变化缓慢的函数的叠加, 这是一个概率密度平均的估计, 其分辨率很低---  
-平均效应较大

$$\mathbf{V}_N = \mathbf{h}_N^d$$

$$\delta_N(\mathbf{x}) = \frac{1}{V_N} \varphi\left(\frac{\mathbf{x}}{h_N}\right)$$

$$\hat{p}_N(\mathbf{x}) = \frac{1}{N} \sum_{i=1}^N \delta_N(\mathbf{x} - \mathbf{x}_i)$$



情形 2: 窗宽  $h_N$  很小, 此时  $\delta_N(\mathbf{x} - \mathbf{x}_i)$  的幅度很大。

此时, 密度估计值是  $N$  个以样本为中心的尖峰函数的叠加, 变化剧烈。当  $h_N \rightarrow 0$  时,  $\delta_N(\mathbf{x} - \mathbf{x}_i)$  趋于以  $\mathbf{x}_i$  为中心的  $\delta$  函数, 估计量变成样本为中心的  $\delta$  函数的叠加----不平滑效应明显

- 因为样本数是有限的，对于实际问题，我们只能折中考虑
- 一般而言，样本数目较多时，窗宽可以取小一些

## 5 估计量的统计性质

$$\hat{p}_N(\mathbf{x}) = \frac{1}{N} \sum_{i=1}^N \frac{1}{V_N} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_N}\right)$$

当满足下列三个基本条件时，**估计量**是渐近无偏和平方误差一致的：



(1) 总体密度  $p(\mathbf{x})$  在点  $\mathbf{x}$  处连续

(2) 窗函数满足下列关系式

$$\varphi(\mathbf{u}) \geq 0$$

$$\int \varphi(\mathbf{u}) d\mathbf{u} = 1$$

保证估计量是密度函数

$$\sup_u \varphi(\mathbf{u}) < \infty$$

窗函数有界

$$\lim_{\|\mathbf{u}\| \rightarrow \infty} \varphi(\mathbf{u}) \prod_{i=1}^d u_i = 0$$

窗函数随着  $\mathbf{u}$  的增加而迅速趋于零

(3)窗宽满足下列条件

$$\lim_{N \rightarrow \infty} V_N = 0$$

$$\lim_{N \rightarrow \infty} NV_N = \infty$$



意义：体积随着  $N$  的增大而趋于零，缩减的速度不能太快，其速率低于  $1/N$

# 6 实例

(1) 标准正态分布的密度函数  $N(0, 1)$

(2) 两个均匀分布的混合密度

$$p(x) = \begin{cases} 1, & -2.5 < x < -2 \\ 0.25, & 0 < x < 2 \\ 0, & \text{其他} \end{cases}$$



窗函数为正态窗函数

$$\varphi(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2} u^2\right)$$


窗宽为

$$h_N = \frac{h_1}{\sqrt{N}}$$

其中  $h_1$  是可以调节的参数（使用者可以选取）

$$\hat{p}_N(x) = \frac{1}{N} \sum_{i=1}^N \frac{1}{h_N} \varphi\left(\frac{x-x_i}{h_N}\right)$$

考察估计量与样本数  $N$ 、可调参数  $h_1$  的关系



讨论:  $p_N(\mathbf{x})$  随  $N, h_1$  的变化情况

①当  $N=1$  时,  $p_N(\mathbf{x})$  是一个以第一个样本为中心的正态形状的小丘, 就是窗函数本身

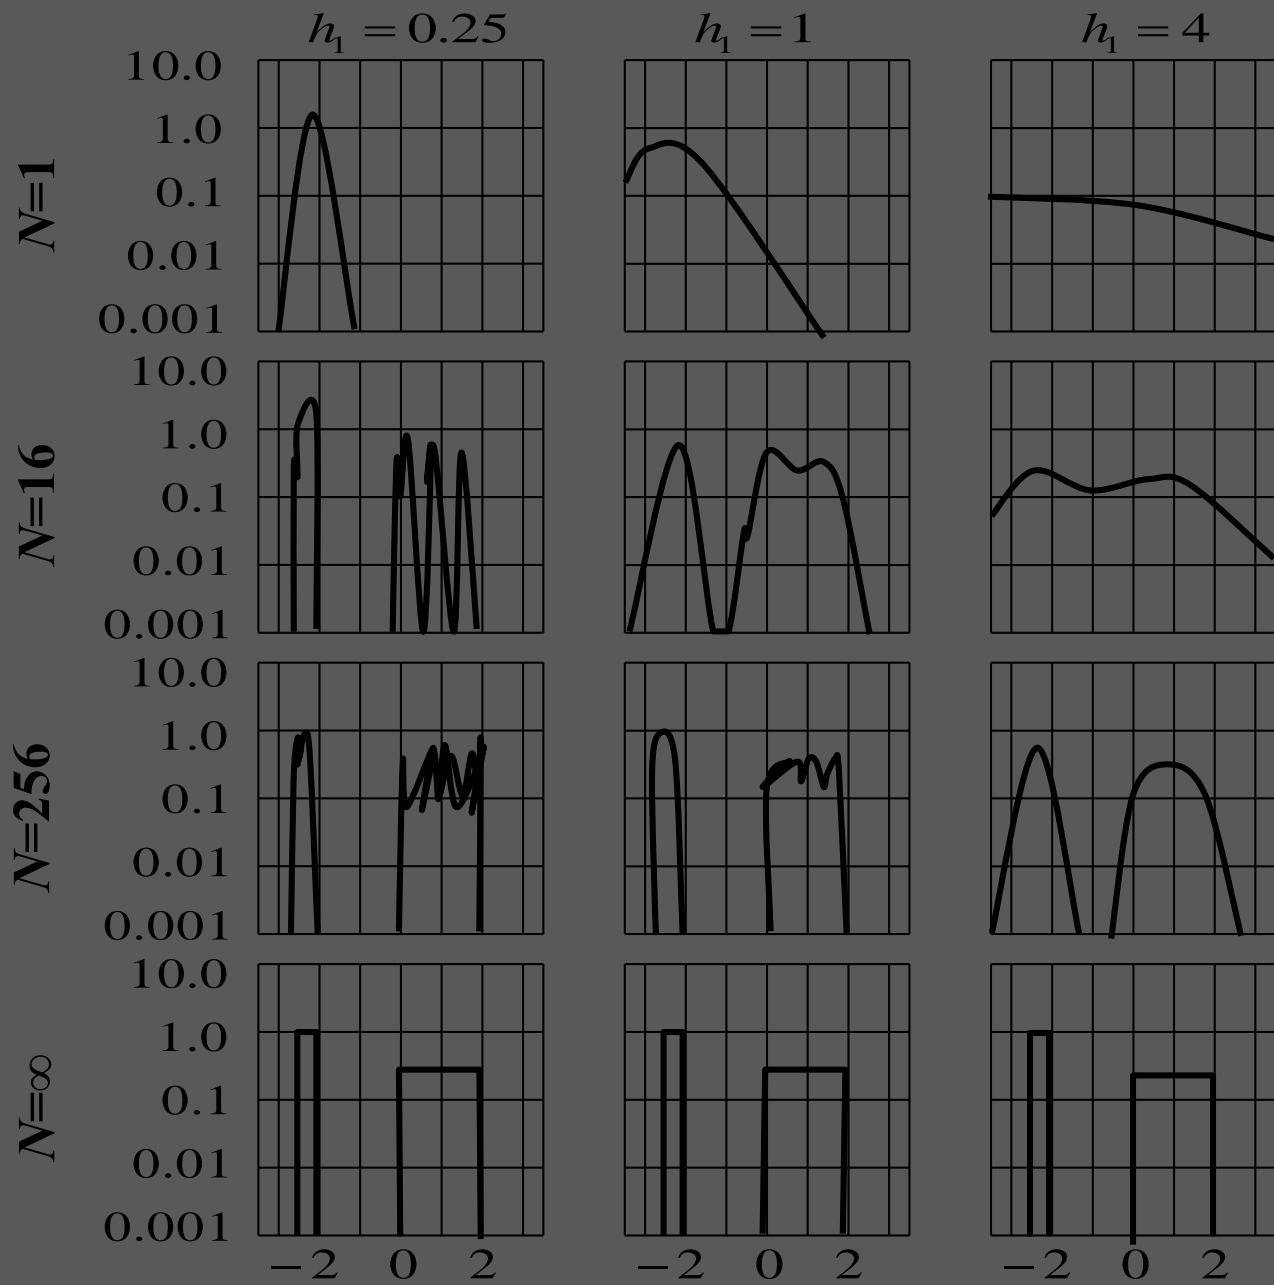
②当  $N=16$  及  $N=256$  时

$h_1=0.25$  曲线起伏很大, 噪声大

$h_1=1$  起伏减小

$h_1=4$  曲线平坦

③当  $N \rightarrow \infty$  时,  $p_N(\mathbf{x})$  收敛于一平滑的正态曲线, 得到了较精确的估计





①当  $N=1$  时,  $p_N(\mathbf{x})$  实际是窗函数

②当  $N=16$  及  $N=256$  时

$h_1=0.25$  曲线起伏大

$h_1=1$  曲线起伏减小

$h_1=4$  曲线平坦

③当  $N \rightarrow \infty$  时, 曲线较好

## Parzen窗法的优缺点：

- ①优点：普遍适应。对规则分布，非规则分布，单峰或多峰分布都可用此法进行密度估计
- ②缺点：要求样本足够多，才能有较好的估计，计算量大，存储量大

使用Parzen窗法时存在的主要困难:

窗宽的选择非常重要，也非常困难。窗宽太大，得到一个较为平坦的分布，反映不出真实分布的变化。如果选得太小，估计量变化太大，很不稳定

### 3.5.3 $k_N$ 近邻估计

Parzen窗法的基本思想：固定体积，每一体积内包含不同数量的样本

$k_N$ 近邻估计基本思想：固定每一个体积内所包含的样本个数，而体积本身的大小可以变化

## 具体做法:

对于给定的  $N$  个样本，我们事先确定  $N$  的某一个函数  $k_N$ ，表示**样本个数**

在点  $\mathbf{x}$  的周围，选择一个体积，不断地扩大，直到捕捉到  $k_N$  个样本为止，这些样本称为  $\mathbf{x}$  的  $k_N$  个近邻

估计点  $\mathbf{x}$  的概率密度为

$$\hat{p}_N(\mathbf{x}) = \frac{k_N / N}{V_N}$$

## 优点:

- (1) 如果点  $\mathbf{x}$  附近的密度比较高, 则包含  $k_N$  个样本的体积就比较小, 可以提高分辨率
- (2) 反之, 如果点  $\mathbf{x}$  附近的密度比较低, 则体积就比较大, 分辨率较低

基本估计公式:

$$\hat{p}_N(\mathbf{x}) = \frac{k_N/N}{V_N}$$







满足的条件是

$$\lim_{N \rightarrow \infty} V_N = 0$$

$$\lim_{N \rightarrow \infty} k_N = \infty$$

$$\lim_{N \rightarrow \infty} \frac{k_N}{N} = 0$$

# 标准正态分布



$N= 1$   
 $k_N = 1$

$N= 16$   
 $k_N = 4$

$N= 256$   
 $k_N = 16$

$N= \text{infinite}$   
 $k_N = \text{infinite}$

# 混合分布



## $k_N$ 近邻法的缺点:

➤ 需要样本多

➤ 计算量大

➤ 存储量大